

从搜索引擎到答案引擎：网易云音乐「觅乐」的 AI 搜索范式重构

发布于 2026-05-28 13:07 · 更新于 2026-06-01 10:18 · 查看权限：全集团所有人

来源: <https://km.netease.com/v4/detail/blog/270770>

导出时间: 2026年8月7日 16:10

摘要

本文介绍网易云音乐在这一跳上的首次系统性落地，载体是搜索组 AI 基建项目「觅乐」，沉淀面向音乐域的内容理解、意图推理与个性化能力，同时赋能 AI 搜与搜推 AGENT。AI 搜一期不开新入口，将答案引擎揉进现有搜索结果页：精搜以锚点歌为起点展开解读与主题化相似推荐，泛搜前置带策展逻辑的 AI 歌单，让一次搜索从「点状检索」走向「网状探索」。

本内容仅代表个人观点，不代表网易，仅供内部分享传播，不允许以任何形式外泄，否则追究法律责任 搜索正在从"帮我找"的检索引擎走向"给我答"的答案引擎。


目录

- 1. 📌 先说结论
- 2. 一、搜索这件事，正在被重新定义
- 3. 二、一期方案：把 AI 揉进搜索结果页
 - 4. 2.1 三类 query，三套方案
 - 5. 2.2 评测先行：AI 产品迭代的节奏，是评测定的
 - 6. 2.3 精搜点后推：从一首歌延伸到一片网
 - 7. 2.4 泛搜 AI 总结：策展即"内容理解 × 个性化召排"
- 8. 三、上线之后：什么立住了，什么没跑透
 - 9. 3.1 立住了的：AI 搜激发了"搜后的探索欲"
 - 10. 3.2 没跑透的：屏效有限位置上的"零和博弈"
 - 11. 3.3 阶段性判断
- 12. 四、一期暴露的三个瓶颈
 - 13. 4.1 内容理解：上限够，但密度和鲜度上不来
 - 14. 4.2 在线链路：核心环节卡在分钟级 RT
 - 15. 4.3 个性化：只在末端，扛不住搜索域博弈
- 16. 五、二期破局：三条主线
 - 17. 5.1 主线一：内容 & Query 理解（地基）
 - 18. 5.2 主线二：在线化（动脉）
 - 19. 5.3 主线三：个性化召排（肌肉）
 - 20. 5.4 三条主线的关系
- 21. 六、从一个模块到一个搜索智能体
- 22. 致谢

💡 先说结论

📌 觅乐：从搜索 1.0 到 2.0 到 3.0 迭代的核心 AI 产品路线

01 用户需求冰山



💡 **核心洞察：**搜索的表层检索难以触达深层需求，
需要从“帮我找”升级为“给我答、替我定”。

02 觅乐产品路线 (1.0 → 2.0 → 3.0)



★ 行业下一站：从“检索效率”到“需求感知”，最终走向“主动决策”。



觅乐是什么？

觅乐是网易云搜索组 AI 基建项目，
沉淀面向音乐域的内容理解与意图推理能力、个性化搜推能力，
同时赋能 AI 搜与搜推 AGENT。



能力沉淀

内容理解、意图推理、
个性化搜推能力



产品落地

支撑从 1.0 到 2.0
的关键跃迁



生态赋能

赋能 AI 搜索与
搜推 AGENT

164

1. 用户理解

搜索这件事，正在被重新定义。过去十几年，搜索引擎沿着「**1.0 搜索引擎**」的范式演进，目标函数始终是**检索效率**（“帮我找”）。这条路做到了成熟水位，却接不住用户表层 query 背后的**需求冰山**。

H1 搜索用研发现当前未被满足好的需求**本质都是策展和延伸，不止是检索**。

- 搜歌意图，50.4%用户期望看到原曲相似歌曲；47.5%期望看到原曲的曲风介绍、发展历程、代表人物和作品
- 搜人意图，59.2%用户期望看到艺人介绍、风格变化史及代表作；33.7%期望看到合作&相似音乐人及作品
- 场景意图，79.5%用户期望得到既适配场景，又符合个性化历史听歌偏好的歌单

2. 行业做法

行业的下一站，是从 1.0 走向「**2.0 答案引擎**」，目标函数从“检索效率”转向“**需求感知**”，从“帮我找”转向“**给我答**”，再往前是「**3.0 决策引擎**」（替我定）。本工作是网易云在 1.0 到 2.0 这一跳上的首次系统性落地，载体是搜索组 AI 基建项目「**觅乐**」，沉淀面向音乐域的**内容理解、意图推理、个性化能力**，同时赋能 AI 搜与搜推 AGENT。

3. 本期解法

我们判断，ai可以带来的增量价值，在于**强化对供给内容和用户需求的深度理解**，并提供对延伸消费内容的**可解释性**，从而针对性提升用户原声中反馈问题的需求满足度。

在产品方案选型上，我们吸取过往竞品经验教训，**主次分明**不影响主需求满足（精准检索）、**不增加用户操作成本**（先学习怎么和ai对话），借势存量需求，把答案引擎揉进现有搜索结果页，分意图针对性改造：

- **精搜“点后推”**，试水流量最集中的搜歌意图，锚点歌消费后展开独家解读 + 带主题、推荐理由的相似好歌
- **泛搜“生成式歌单”**，AI 总结前置到结果页顶部，直出分主题、带卷首语、逐首带解读的个性化策展歌单

一句话概括产品判断：**让一次搜索从「点状检索」走向「网状探索」**。

4. 验证效果

4月AB实验效果：策略流量下，精搜场景搜索人均有效时长 +0.135min；泛搜场景大盘人均有效播放时长 +1min；用户的探索欲被明显抬起，第二屏起的歌单、艺人、笔记、视频、播客曝光率全面 +4~+9pt。

AI 搜的价值**不止在自己产生多少点击，更在它打开了用户的“再探索开关”**，一次搜索从查询的终点变成了内容探索的起点。

5. 全局价值


放大到平台视角，用户输入的每一次query，都等于一次高密度偏好表达。若能提升搜索发现性，就有机会放大一次性查询的偏好信号采集效率。搜索的战略定位会从“需求满足工具”升级为“**用户主动意图采样器**”：推荐猜“过去喜欢什么”，搜索基于此刻 query + 后续反馈识别**“现在想听什么、还能喜欢什么”**。每次查询都是一次可观测的**偏好实验**，反哺推荐形成**数据飞轮**，这才是 2.0 对大盘真正的杠杆。

下面附上几张真实结果页 case，先直观感受形态。

【AI搜 - 精搜案例】



【AI搜 - 泛搜案例】



一、搜索这件事，正在被重新定义

过去十几年，搜索引擎的迭代方向相当一致——让信息检索效率不断提升。无论是 Google、百度，还是音乐 App 里的搜索框，整个行业都在围绕"用户给一个 query，更快、更准地把对应的资源返回出来"这件事卷。版权覆盖、文本相关性、语义召回、用户行为协同，一代代技术叠上去，传统搜索已经把"检索"这件事做得相当成熟。但**成熟不等于到顶**，真实的情况更微妙：**传统搜索做到了"找得到"，但还没做到"懂得透"**。

网易云的搜索数据按用户意图大致可以分成两类：

类型	占比	典型 Query	用户期待
精准搜索	~70%	"晴天"、"周杰伦"、"甄嬛传主题曲"	找到那个明确的目标
宽泛搜索	~30%	"下雨天听的歌"、"婚礼上放的"、"90 后青春"	找到对的氛围 / 情绪

传统搜索把这两类都"接住"了，但接的方式是同一套——**把它当成一个"检索效率问题"来解**。无论输入的是一首具体的歌还是一个模糊的场景，系统的工作都是"按字面 + 语义最相关的内容把资源取回来"。这套打法解决得很好是显性需求，但有两件事它接不太住。

第一，深层情绪需求没有被显式感知。 一个用户搜"下雨天听的歌"，他要的可能不是"歌名带雨字的歌"，也不是"被收录进各种'雨天歌单'的歌"——他要的是某种心境：可能是慵懒、可能是孤独、也可能是温暖。系统能把氛围相关的歌取回来，但它不会跟用户解释、不会给推荐理由、不会讲这首歌的故事。**它只完成了"匹配"，没完成"沟通"**。

第二，很多用户的潜在需求根本没说出口。 从产品视角看，网易云用户的主流需求是情绪调节，主流场景是伴随式音乐消费——开车、做饭、洗澡、写代码、睡前。这些场景下用户脑子里浮现的不是某首具体的歌，而是一种状态。但状态这种东西，用户不一定有意愿、也不一定有能力把它清晰地表达进搜索框。久而久之，因为系统不曾以"理解状态"的姿态接住过他们，他们就不在搜索框里表达了。这部分**"被压抑的沉默需求"，可能比那 30% 的显性宽泛搜索还要大得多**。

这两件事，传统搜索的"检索效率"路径其实接不住——因为它的目标函数是"返回最相关的资源"，而不是"理解用户当下的状态"。要接住它们，搜索需要做一件性质不同的事：**透过用户表层的资源检索需求，利用语义理解和资源知识网络的搭建，去放大那部分深层的情绪需求感知。**

LLM 让这件事第一次变得可行。 模型能做几件传统搜索做不到的事——它能把"婚礼上放的"翻译成对应的氛围属性；它能给一首歌写一段解读，告诉用户"这首歌为什么跟你的心境对得上"；它能基于一首歌往外扩展出一张内容网络——这首歌的同流派、它的翻唱版本、它的影视背景、它适合的场景。**这些事的本质都不是"提升检索效率"，而是"加深需求感知"。**

行业里的玩家也都在试 AI 搜，路径上看下来大致三种：

打法	代表产品	形态
----	------	----

单做对话入口	QQ 音乐、汽水	搜索之外开一个独立 AI 聊天界面
接通用 AI 工具	Spotify+ChatGPT、Apple+ChatGPT	借外部模型生成歌单
揉进现有动线	Amazon Explore、QQ 播放页 AI 解读	不开新入口，在原路径里塞 AI 增量

第一种打法最直观，缺点是把用户从原来熟悉的搜索动线拉走，要重新养心智；第二种最省事，但通用模型对音乐资源没有 ID 级的理解，结果质量受限于外部能力；**第三种最难**——它要求每一次搜索的每一个节点都做精细化设计，不能让用户感觉到"这是个 AI 模块"，而是让 AI 自然地成为搜索结果的一部分。

网易云 AI 搜走的是第三条。理由也直白：用户已经习惯了综合页那一套节奏——搜一个词，看最佳匹配、看歌单、看热点卡片，一气呵成。这种习惯不是几个月能改的。比起在外面新搭一个 AI 入口让用户重新学习，更稳的做法是让原来的搜索结果"立体起来"——搜到一首歌，不再只看到这首歌，还能顺着它继续往下：它的解读、它的同类、它属于的某个氛围。

这件事可以概括成一句话：**从「点状检索」走向「网状探索」**。一次搜索不再是查询的终点，而是一次内容网络的入口。这个判断决定了一期做什么、不做什么——**做**：把 AI 揉进精搜结果页的"点后推"、揉进泛搜结果页的"AI 总结"；**不做**：独立的 AI 对话入口、独立的 AI 落地页（这部分留给二期再考虑）。

二、一期方案：把 AI 揉进搜索结果页

2.1 三类 query，三套方案

产品定位明晰后，落地的第一步是把搜索 query 拆类，针对性设计技术方案。AI 搜的服务范围拆成三类：


类型	用户状态	AI 能干的活	一期形态
精搜	已经搜到目标	"延伸"——讲讲这首歌的故事、推它的同类	结果页点后推：歌曲解读 + 相似推荐
泛搜	描述场景 / 情绪	"策展"——挑出符合氛围的歌 + 解读	结果页顶部 AI 总结：歌单 + 文案
中长尾	低频长尾 query	"兜底"——补内容空缺率	

在展开具体技术方案之前，需要先说明一件比方案本身更重要的事——**评测**。

2.2 评测先行：AI 产品迭代的节奏，是评测定的

传统算法的迭代节奏靠 AB 实验拉齐：模型 A 比 B 好多少，看 CTR、看时长，数据一拉一目了然。但 AI 生成的内容套不进这套范式——一段歌曲解读"好不好"，没有 CTR 这类指标能直接量化；而完全依赖线上 AB 又走不通，一次 AB 起码两周才能拿到一组数据，加上外部大模型单次推理动辄几十秒，端到端拉一轮实验的成本极高。**这种迭代节奏在 AI 时代是完全不可接受的——必须有一套能在线下、小时级跑完的评测体系，把决策从"等 AB"前置到"等评测"。**

所以一期开工的第一件事，不是写召回、不是写排序，而是**先把评测基建搭起来**。算法同学用 vibe coding 半天时间搭出了一套**自动化评测前端平台**——产品、运营、算法三方在同一套界面上对每条结果打分、对比、记录，告别"群里发截图来回讨论"的低效模式。这件事本身也是一次 AI Coding 与业务深度结合的实践：原本至少一周的前端开发量被压到了半天，**评测从"待办需求"直接变成了"开工当天就能用的工具"**。



平台上线后效果立竿见影：**每一版改动 24 小时之内就能拿到分数**，没有这个平台，可能一周才能拿到一次反馈。这种节奏的变化，是后续所有 prompt 工程、链路调优能快速收敛的前提。

与评测平台同步落地的，是一套覆盖 **七个维度** 的打分体系，从"对不对"、"全不全"、"有没有用"到"读起来怎么样"逐层覆盖：

维度	衡量什么
相关性	推的歌跟 query 主题对不对
准确性	文案和事实有没有出入（比如说错乐器、说错艺人）
多样性	歌曲分布是否过于集中、模块之间有没有重复
有用性	用户看完会不会想点
创新性	角度有没有惊喜，会不会让人觉得"这个角度有意思"

个性化	是不是这个用户会喜欢的（而不是泛泛的"大家都会喜欢"）
文风	文字读起来像不像人话，会不会"AI 味"过重

一期沿着这七个分跑了三版迭代，精搜和泛搜的关键变化对照如下：

维度	精搜 V1	精搜 V2	精搜 V3	泛搜 V1	泛搜 V2	泛搜 V3
相关性	3.69	3.75	3.61	3.76	3.65	3.73
准确性	3.72	3.83	3.68	3.61	3.77	3.70
多样性	3.56	3.42	3.52	3.39	3.50	3.76
有用性	3.49	3.48	3.71	3.36	3.58	3.78
创新性	3.39	3.19	3.42	3.19	3.27	3.59
个性化	3.05	3.21	3.57	2.88	3.42	3.50
文风	3.13	3.44	3.72	1.96	3.54	3.74
综合	3.43	3.47	3.60	3.16	3.53	3.69

三版下来有几件事变得清楚：

- **准确性、相关性这类"硬维度"得到保障。** LLM 单纯做"基于事实的内容生成"，靠 prompt 工程已经能压到接近上限——再调有边际收益，但不会再有质变。
- **多样性、有用性、文风这几个"中间维度"涨幅最快。** 它们本质上是 prompt 工程的红利——把规则写清楚、把 few-shot 给准确，模型就能学到。在 prompt 里加了"维度独特性挖掘"和"表达润色"两条规则，文风分立刻能上涨。
- **创新性、个性化维度分较低。** 原因不复杂——它们靠的不是 prompt，而是模型对内容本身和用户本身的理解深度。让大模型"想得更深"是不够的，还得让它"知道得更多"——而知识从哪来，是 prompt 工程解决不了的事。

评测平台是一期最重要的一项基建。 它的价值不在评测本身，而在于把"AI 产品的迭代周期"从"等 AB"压缩到"等评测"——这是 AI 时代算法迭代节奏的根本变化。

2.3 精搜点后推：从一首歌延伸到一片网

2.3.1 想法的源头：从「启发式检索」到「点后推」

精搜的产品形态不是凭空想出来的，源头可以追溯到 2023 年组内启动的「启发式检索」项目。

那个项目背后的产品判断是：用户在搜索场景下并不一定都"知道自己要什么"，他们脑子里通常带着一种朦胧的心境（比如"听到《晴天》了，但其实想多听几首类似的"），而传统搜索只能精确响应字面输入，对这种潜在心境没有承接。「启发式检索」想做的事是：结合用户的搜索意图给出更多被推荐的内容，以搜带推，启发用户扩展消费，最终找到心仪的歌。

它跟纯推荐的本质区别在于**有没有锚点**。纯推荐基于全部行为画像猜用户喜欢什么，是无锚点的；启发式检索是有锚点的约束性推荐，刚搜了《晴天》就是一个强信号，所有推荐都必须围绕这个锚点展开。


精搜点后推延续的就是这套思想。用户搜到一首歌时，大概率不只是想"听这一首就走"，背后多半带着某种心境：可能想沉浸在这种风格里多听几首，可能想了解这首歌的故事，也可能想看看这位艺人的同类作品。点后推的设计就是要把这种心境"接住"，在用户搜到目标歌的那一刻，顺势展开一片相关的内容网络，让一次"点状检索"变成一次"网状探索"的起点。

启发式检索本身已经在搜索场景跑了两年多，证明了"以搜带推"这套产品形态是成立的。AI 搜在它的肩膀上往前走一步，把原本基于行为协同的"启发"，升级为基于内容理解的"启发"。这一升级带来两个变化：

维度	启发式检索（2023 ~ 至今）	AI 搜点后推（2026）
推荐依据	用户行为协同	内容多维理解 + 行为协同
解释能力	黑盒，无解释	自然语言解读，逐首给推荐理由
维度组织	平铺一组维度相似歌	按主题聚类，每个主题独立成模块

2.3.2 链路总览

精搜点后推的整条链路五步走，从锚点歌出发，最终生成一组带主题、带解读、带个性化排序的相似推荐：



整条链路的设计原则有三条：**重的算力放离线、能并发的环节不串行、LLM 的输出必须有结构化兜底**。每一步的选型都贴着"既要内容理解的深度，又要工程落地的可控性"在做权衡。下面把五步串起来讲。

2.3.3 五步详解

第一步：歌曲多维内容理解。表面上是"写文案"，本质是对一首歌做多视角的语义建模。一期把这一步拆成双线并发，两路之间没有依赖，并发起来直接砍掉一半 RT。

一路是 **LLM 原创解读**。给定歌曲的歌名、艺人、专辑、流派、词曲创作信息等结构化数据，让大模型生成一段解读文案。难点是"解读出独特的角度"：一首歌从词、曲、唱、文化背景、情绪表达、时代意义任一维度都能解出来，prompt 必须引导模型每次都挑出"最值得讲的角度"，而不是面面俱到讲成八股文。一期在 prompt 上沉淀的核心规则是"独特维度挖掘 + 表达润色"——让模型先穷举可挖掘的维度，再选其中差异度最大的一个深入讲，最后过一遍口语化润色。

另一路是 **评论语料治理 + 仿写**。云音乐的 UGC 评论本身就是一份高质量语料，但直接拿来用不行，评论区里五花八门：歌曲描述、名言鸡汤、负面攻击、纯打 call 抄歌词、无关灌水都有。具体做法是用 LLM 做一个负向分类过滤层，把评论按上述五类分类，只保留前两类（歌曲描述作为仿写素材、名言鸡汤作为情感共鸣素材），再让 LLM 基于这部分高质量评论"仿写"出短评。这样产出的文案天然带着真实用户语料的"人话感"，而不是完全的 AI 腔。一期 V3 文风分能跑到 3.72，这一路功不可没。

第二步：多源异构召回。 这一步是整条链路的"原料车间"，决定后面 LLM 能聚出什么主题，本质上取决于召回池里有什么货。一期采用双引擎双路召回，两路逻辑正交：


路径	召回信号	解决什么问题
搜索域生成式向量	基于全站用户红心行为预训练 + 搜索推荐场景下的消费序列微调	抓"搜索语境下的真实消费相似性"，比通用相似度更贴用户行为路径
歌单语义协同	BGE 中文向量在站内歌单标题与描述上 finetune，再叠加歌单质量与播放数据筛选	抓"出现在什么样的语境里"，补主题与场景维度

第一路的核心是**生成式预训练 + 场景化微调**这套范式。常规向量召回大多走的是 item2vec / 双塔这类对比学习路径，学到的是"哪些歌经常被一起听"这种共现关系。一期走的不是这条路，而是把推荐侧成熟的**生成式预训练**思路引到搜索域：以全站用户红心序列作为高置信偏好语料预训练歌曲表征，让模型在序列建模任务上学到歌曲的语义；再用搜索推荐场景下的真实消费序列（搜索曝光、点击、有效播放、收藏）做下游微调，把"用户在搜索路径上的偏好结构"显式注入到向量空间里。这种向量带来的最大优势是它本身就承载着"搜索语境下的相似性"——搜《晴天》召回出来的不只是听感相近的歌，更是真的会被用户在搜索路径上一起消费的歌，包括心境一致、年代接近、播放列表里的常邻居这种行为意义上的相似。

第二路歌单语义协同的逻辑跟第一路正交，它不看"歌本身像不像"，看的是"歌出现在什么样的语境里"。具体做法是：先用 BGE 中文向量模型在站内歌单标题、描述上 finetune，得到歌单的高质量语义表达；在语义召回的歌单里再叠加用户行为信号（播放质量、热度分位）做筛选；最后从筛出来的高质量歌单里按歌曲匹配度取 Top-K 入池。这一路本质上是"语义 + 行为双层协同"，先用 finetune 后的语义向量找到主题相关的歌单，再用行为数据筛掉"虽然主题相关但实际质量差"的歌单，候选既有主题一致性又有真实消费数据背书。

单走第一路结果偏"风格雷同"（搜《晴天》易堆周杰伦风抒情），单走第二路偏"场景一致但风格混乱"（搜《晴天》可能因 KTV 歌单关联推到《浮夸》）。两路并行召完后做去重合并、记录来源标签，"双路命中"作为更强的相关性信号保留给下游。

第三步：基于内容理解的 LLM 主题建模。 这一步是一期技术含量最高的环节，难度不在"让 LLM 多写两段话"，而在**怎么把组内沉淀多年的音乐内容知识喂给 LLM，让它做的是"基于既有知识的归纳"，而不是"凭借自身常识的发挥"。**



LLM 单独做主题建模，有两个先天问题：一是它对长尾歌曲、华语小众艺人、影视 IP 关联的认知远不如组内数据沉淀深厚；二是它会"自信地编"，幻觉风险天生存在。一期没有把这一步交给 LLM 一个人完成，而是给它配了两份"必须基于"的事实底座：

输入来源	喂给 LLM 的内容	作用
第一步「歌曲多维内容理解」的产出	锚点歌的解读、候选歌的解读	把每首歌的"个性化视角"显式提供，避免 LLM 用通用印象代入
组内基建「结构化内容理解」知识库	曲风、流派、年代、影视 IP、词曲创作背景、文化标签等多维结构化字段	把站内多年沉淀的音乐知识作为事实约束注入 prompt

LLM 在一次推理里要做的，是给定锚点歌、锚点解读、关联歌单名、候选歌曲池、以及上述两份知识之后，对整个候选集做一次**语义层面的归纳**：自适应判断这次该聚成几个主题、每个主题用什么维度切分、每个主题选哪些歌。它扮演的是"懂音乐的归纳者"，而不是"凭空写主题的创作者"。所有主题命名、维度切分、歌曲归类，都必须在喂入的知识范围内闭环，越界即视为幻觉。

举个例子：搜《七里香》和搜《以父之名》，候选池都来自周杰伦的曲目，但聚出来的主题维度完全不一样，前者会涌现出"夏日青春 / 校园纯爱 / 周式抒情"，后者会涌现出"中国风 / 叙事感 / 配器深邃"。维度不是预设的，而是 LLM 在咀嚼站内知识库的多维属性后，根据候选集的内在结构归纳出来的。

整个建模过程是 **"事实底座 + 语义建模"两层协作** 的结果：

分层	来源	承担的事
----	----	------

事实底座	结构化内容知识库 + 第一步歌曲解读	提供曲风、艺人、年代、词曲创作、影视 IP 等多维事实，划定"可用素材"边界，越界即判幻觉
语义建模	LLM	在边界内做主题涌现、模块切分、命名润色与推荐理由生成

事实底座保证"说得对"，语义建模保证"说得活"，两层耦合是评测里"文风"能跑到 3.7+、"准确性"同时稳在 3.7 的根本原因——LLM 真的在做内容建模而不是套模板，幻觉也没被留出窗口。

第四步：解析与一致性校验。 LLM 输出的 JSON 偶尔会出现格式漂移、字段缺失、模块标题与歌曲不一致等问题。一期做了多层兜底：格式走正则提取 + 容错解析，语义层做模块标题与歌曲一致性校验（例如模块叫"粤语金曲"但混入日语歌则整模块丢弃），字段缺失直接跳过。这一层不"提分"，保的是不出"低级翻车"。

第五步：多目标个性化排序。 每首歌过一次个性化打分模型，模块内按分数降序、模块间按平均分降序，匿名用户跳过打分。一期复用了启发式检索沉淀下来的多目标排序模型（点击、有效播放、收藏等联合输出综合分），快速上线。但该模型并未针对 AI 搜场景建模，曝光形态、内容形态、消费意图都有差异，二期会换成 AI 搜专属排序模型，这部分留到第四章瓶颈再展开。

2.4 泛搜 AI 总结：策展即"内容理解 × 个性化召排"

2.4.1 想法的源头：从「延伸」到「策展」

精搜的难点在"延伸"，泛搜的难点完全不一样。用户给一句模糊描述（"婚礼上放的"、"90 后青春回忆"、"学习提神的"），结果页顶部要直接给一份"AI 策展过的歌单 + 解读"。

精搜有锚点歌可以围着扩，泛搜什么都没有，全靠对 query 本身的理解。一首歌跟"婚礼"有没有关系，这个问题不是查标签能回答的，需要模型理解"婚礼"这个场景背后的氛围（喜庆但不闹腾、动情但不悲伤），再去判断哪些歌满足这种氛围。

回到第一章对业务问题的判断：泛搜词在传统搜索里其实并不是"召回不到"。云音乐搜索域多年沉淀下来的语义召回、行为协同已经能把氛围相关的歌检索出来，"下雨天听的歌"也能召回到一批氛围对的候选。真正接不住的**不是"召回"**，是这两件事：**没有把候选组织成一份带氛围、带主题的个性化结果，以及没有给用户解释"为什么这一组歌跟你的描述对得上"**。前者本质上是策展能力的缺位，后者本质上是沟通能力的缺位。

AI 搜泛搜总结要补的，正是这两块缺口。它不是去替代搜索的语义召回，而是接在召回之后，把一组候选歌**重新组织成"主题聚类 + 卷首语 + 每首歌推荐理由"的策展输出**，再叠加 query × user 的个性化重排，让结果不仅"找得到"、还"讲得清"、且"贴得上每个用户"。这一层做不做，决定了泛搜 query 下用户拿到的是"一堆氛围相关的歌"，还是"一份氛围对、有解读、还合自己口味的歌单"。

2.4.2 链路总览

泛搜 AI 总结的整条链路五层走，从 Query 出发，最终生成一份带主题、带卷首语、带个性化排序的策展结果：

泛搜 AI 总结链路总览（五层）

从 Query 出发，生成带主题、带卷首语、带个性化排序的策展结果



整条链路的设计原则有三条：**贵的算力放离线、毫秒级查询放在线、双轨召回相关性与猜中率并重**。这套架构让一期的泛搜在外部大模型分钟级 RT 的现实下，仍能在搜索结果页里实时返回。下面把五层串起来讲。

2.4.3 五层详解

第一层：意图理解。 这一层做的是“翻译”，把用户嘴里的话翻成系统能听懂的属性。“下雨天听的歌”对系统来说本是一串字符，意图理解会把它翻成一组音乐侧的语义标签：情绪是治愈、慵懒，流派是 lofi、轻爵士，场景是独处、深夜。下游召回拿到的不再是“雨”这个字，而是这组真正描述用户期待的属性。

工程侧的关键决策是把这套映射从“在线现算”沉到“离线预生产”：圈选范围内的 query 提前过一遍 LLM，产出标签落键值缓存，线上只查表，请求路径不再触碰大模型。算法几乎不动，但在线 RT 从分钟级压到毫秒级，是一期能塞进搜索结果页的前提。代价是只有圈选过的 query 才命中，这也是后文“链路太重”瓶颈的伏笔。

第二层：双轨多路召回。 拿到了一组语义标签，下一步是去全库捞货。一期采用的是双轨并行召回，一条轨道盯着“主题对得上”，另一条轨道盯着“用户对得上”，缺一不可：

轨道	召回路径	解决什么问题
语义召回	主搜召回 + 歌单生成式检索召回 + 歌曲向量 RAG (768 维语义检索)	歌跟主题对得上
个性化召回	个性化向量召回 (用户长短期行为 + Query 联合检索) + 已消费歌曲提权	歌跟这个用户对得上

语义召回是"猜中主题"那一路。给定"治愈 / lofi / 慵懒钢琴"这组标签，它要做的就是从全库里把符合这些属性的歌全部捞出来，跟用户是谁没关系。其中歌单生成式检索这一路是新意所在：传统做法是"把标签变成向量、再去近邻搜索"，一期换了个思路，把"按标签找歌单"直接建模成生成式问题，让模型把匹配标签的歌曲 ID 一个个生成出来。这种做法在长尾标签上覆盖更密、相关性更稳，是搜索域生成式范式的延伸应用。歌曲向量 RAG 那一路则保留传统语义近邻检索，用站内语料 finetune 后的 768 维向量做兜底，跟生成式检索互为补充。

个性化召回是"猜中用户"那一路。同一句"婚礼上放的歌"，喜欢粤语流行的用户和喜欢英文经典的用户期待的结果完全不同。怎么把"用户是谁"塞进召回？一期的做法是先把用户长短期行为序列通过**向量量化**压成一串离散语义 ID（可以理解成把用户的兴趣翻译成一组"音乐基因码"），再让这串编码跟 query 在同一个向量空间里联合检索。比起常规连续向量表征，这种离散编码既保留了语义结构，又便于跟 query 拼起来一起算分。

两路并行召完后融合在一起。内容轨保住"主题不跑偏"，个性化轨保住"猜中用户口味"，缺哪条都不行：只走内容轨，谁来都给同一份歌单；只走个性化轨，可能给出一堆用户喜欢但跟"婚礼"无关的歌。

第三层：相关性 + 个性化加权排序。召回阶段把"够格"的歌都拉了进来，但这一堆候选谁排前谁排后还需要过一层排序。一期的做法很直接：算两个分，一个是"这首歌跟 query 有多匹配"（相关性分，看情绪、流派、场景标签的对齐度），一个是"这首歌这个用户有多喜欢"（个性化分，看用户兴趣画像），两个分加权融合成综合分。这一层不出文案，但决定了下一层 LLM 看到的"原料"是不是够好。

第四层：LLM 策展。这一层跟精搜的"主题建模"是同一套思路，让 LLM 看完候选歌之后做四件事：把歌分主题、给每个主题写卷首语、给每首歌写一句推荐理由、再把整体串成一份完整的策展输出。区别在于精搜的锚点是一首具体的歌，泛搜的锚点是 query 本身。

策展比写文案难，因为 LLM 要在一次推理里同时回答四个问题：

问题	含义
这个 query 应该聚成几个主题？	例如"90 后青春回忆"可能聚成"台偶 OST / 青春偶像 / 校园民谣 / 网络神曲"四块
每个主题选哪些歌？	在候选池里挑出最符合该主题的歌
怎么解释这个主题？	写一段卷首语，讲清楚这一组歌为什么放在一起
怎么解释每首歌？	给每首歌一句推荐理由


跟精搜第三步同样，这一层依靠"事实底座 + 语义建模"两层协作。意图理解阶段产出的多维标签是策展的边界，组内结构化内容知识库是策展的素材库，LLM 在边界和素材范围内做主题涌现和文案润色，越界的命名和归类都视为幻觉。

第五层：离线落库 + 在线接入。整条链路从意图扩展、召回、聚类到文案生成，处处是大模型在干活，跑一遍下来端到端是分钟级的，这种 RT 在搜索结果页里完全不可接受。一期的解法是按"贵慢的放离线、快的留在线"切一刀：

计算	位置	原因
意图扩展、召回、聚类、文案生成	离线 pipeline	大模型推理慢、贵，但结果可批量复用
缓存查询、个性化排序	在线服务	毫秒级响应

离线把贵的活儿提前算完，在线只查结果。这套切分让一期泛搜在大模型分钟级 RT 的现实下仍能实时返回，但代价是只有提前圈选进离线 pipeline 的 query 才能用上 AI 总结，圈选之外的请求完全没有这套能力。这是工程上的妥协，也是后面“链路太重”瓶颈的直接来源，二期会通过 NLU 蒸馏 + RAG 把核心环节真的搬到在线，让覆盖摆脱圈选限制。

三、上线之后：什么立住了，什么没跑透



4 月 AI 搜一期外投上线，开 AB 实验。两周之后拿到数据，整体看下来是三个场景三种走向，数据本身谈不上“压倒性的赢”，但它给出了一组比“大盘有没有涨”更值得展开的信号：**AI 搜在做什么、用户怎么用、以及这件事的真实价值落在哪里**。下面分两块讲，一块是数据立住了的，一块是没跑透的。

3.1 立住了的：AI 搜激发了“搜后的探索欲”

最直接的正向信号不是 AI 模块自己的点击率，而是它上线之后，整个搜索结果页的“探索深度”被明显拉了起来。

精搜场景下，AI 相似好歌模块出现之后，结果页第二屏往后的内容曝光率全面提升，歌单、艺人、笔记、视频、博客的 UV 曝光率均有 +4~+9pt 的涨幅。用户拿到一首目标歌之后，开始愿意往下翻、往周边看。**第一章那句“点状检索 → 网状探索”的产品判断，在数据层面真的发生了。**

泛搜场景下，AI 总结模块自己的消费数据并不亮眼，但它把流量导到了下方更专业的歌单形态：综合页歌单页曝光率 +3pt，歌单模块和歌单 tab 的有效播放时长同步上涨。换句话说，AI 模块没把消费“截留”在自己身上，而是**把用户领进了更专业的歌单形态里**完成消费，最终大盘人均有效播放时长 +1min、有效播放人数 +0.25pt。

行为细节也呼应了同一件事：相当一部分泛搜用户会横滑对比不同歌单、点击进入浮层、看完文案再决定播放哪首。这种“多挑、再选”的探索态度，跟传统搜索“直接播放走人”的行为模式完全不一样。

这背后还有一层更深的产品判断被印证了：**AI 搜的真实价值不在于自己拿走多少点击，而在它打开了用户的“再探索”开关。**一期立项时给精搜和泛搜分别下的两个机会点：精搜负责“转化用户主动表达后的消费势能”，泛搜负责“用个性化+可预览的内容降低决策成本”，都从这两组数据里得到了直接验证。

一次搜索不再是查询的终点，而是一次内容探索的入口，这件事不再是产品判断，而是数据事实。

3.2 没跑透的：屏效有限位置上的“零和博弈”

不那么乐观的一面是：AI 搜模块上线之后会挤压同屏其他高效率模块的曝光，全局账上抵消掉了一部分 AI 搜本身带来的正向。

精搜场景下，AI 模块本身在搜索域贡献了正向（人均有效播放时长 +0.135min、人均有效播放次数 +0.03），但同屏的最佳匹配、单曲推荐曝光被挤压，赢的位置和被挤的位置在大盘上互相抵消，最终整体表现被中和到“持平”。

泛搜场景下这种抵消更明显：AI 生成歌单替换最佳匹配的位置之后，**综合页有效有点率下降**，并且 AI 模块自己的有效有点率也比同位置的最佳匹配、热点卡片要低。也就是说，AI 模块本身贡献的正向，并不足以覆盖把最佳匹配挤掉所损失的时长。整体能跑正，靠的是用户被导流到下方歌单模块和歌单 tab 之后的消费在做托底，本质上是“借东墙补西墙”。

零和博弈的根因，不只是“屏效有限”这一个外因，更深一层是**一期的意图理解还不够细，AI 模块对所有 query 一刀切触达**，而真实的用户需求差异度远比这套切法大：

- **精搜场景**：用户搜一首歌，可能是“首次听”想要拓展，也可能是“反复听”只想直接播放走人；可能是“独立主题”歌（一首流行单曲），也可能是“系列主题”歌（儿歌、影视/游戏 IP 主题曲）。前者对 AI 解读 + 相似推荐有强消费意愿；后者更可能奔着“原曲就走”，AI 模块在这种 query 下挤掉最佳匹配，纯属负效率。
- **泛搜场景**：用户描述一个生活场景（“通勤听的”）和一个权威性需求（“钢琴助眠”）下的最佳承接形态完全不同。前者 AI 总结的策展能力是加分项；后者站内已经有成熟的“助眠专区”在直接 PK，AI 总结挤占专区位置反而拉低效率。

意图侧不分级，挤压就是一刀切：存量模块在它们擅长的 query 上被压下去，AI 模块在它不擅长的 query 上又顶不上。零和博弈在这两端被同时放大。

二期会从三条路径同时收这件事：

- **意图侧**：把 query 类型识别（首次 / 反复、独立 / 系列、生活场景 / 权威需求等）做进意图理解，AI 模块只在自己有正向收益的 query 上触达，分级触发而非一刀切。
- **排序侧**：把 "AI 模块对其他模块的挤占效应" 显式建模到排序里，只有在 AI 模块预估收益大于被挤模块预估损失的时候，才让它出现在显眼位置。
- **链路侧**：把核心环节从离线预生产真正搬到在线实时个性化生成，用更高的内容密度和个性化命中率去对冲屏效约束，让 AI 模块在同样的篇幅里跑出比存量模块更高的效率。

3.3 阶段性判断

两块放一起看，一期给出的真正答案不是 "AI 搜值不值得做"。这件事已经从探索欲、信息消费形态、以及用户行为模式上得到了正面印证。真正的答案是：AI 搜的天花板被三件事压住了。**意图理解一刀切让 AI 模块在不该出现的 query 上挤掉了存量高效模块；屏效约束在这之上进一步放大零和博弈；离线预生产又让它的覆盖密度和个性化深度都上不去。**

换句话说，一期证明了方向是对的，但能力还没把这个方向跑透。下一章会把这些瓶颈一条条展开，二期的所有动作都在围着这些瓶颈做。

四、一期暴露的三个瓶颈

AI 搜的天花板被三件事压住了：意图理解一刀切放大了屏效上的零和博弈、离线预生产让覆盖密度上不去、个性化只在末端扛不住搜索域竞争。再往下拆到能力层，对应三个具体瓶颈。



4.1 内容理解：上限够，但密度和鲜度上不来

一期可以做出"唐恬笔下的岁月长诗、热气腾腾的归乡底色"这种细颗粒度的内容理解。这说明大模型的能力够、prompt 调到位也能解出来，**理解的上限是高的**。

代价是每一次产出这种理解，都要让大模型现场推理一遍。成本高、耗时长，规模化做不动。

这种依赖的本质是：**一期没有把"内容理解"做成系统的内生能力，而是每次都在临时借用大模型的算力**。后果是理解的"密度"和"鲜度"都上不来。没法对全库几千万首歌都做这种深度理解，只能对召回到候选池里的那几百首做。

二期要做的，是把这种"现场推理才能得到的理解"沉淀成"离线就已经有的知识"：让每一首歌都有一份多维主题档案，让每一个 query 都有一份意图细分，让下游的召回、排序、文案、RAG 都吃同一份知识，而不是各自再现场让大模型推理一遍。

4.2 在线链路：核心环节卡在分钟级 RT

一期的核心环节都是大模型在干活，端到端 RT 是分钟级。这种 RT 在搜索结果页里完全不可接受，用户输入完 query 必须秒级看到结果。

一期能上线，靠的是一种工程妥协：把圈选范围内的 query 提前在离线 pipeline 跑完，结果落缓存，线上只查表。这种妥协的副作用是 **覆盖范围有限**，能用上 AI 搜能力的只有圈选进离线 pipeline 的那部分 query，圈选范围之外的请求完全没法享受 AI 搜的能力。

二期要做的是把核心链路真的在线化，具体两件事：

- 通过 **NLU 蒸馏** 把意图识别从大模型压到小模型；
- 通过 **RAG** 把文案生成从"大模型从零现写"压成"检索事实 + 轻量拼装"。

让整条链路从分钟级压到秒级，覆盖摆脱圈选限制。

4.3 个性化：只在末端，扛不住搜索域博弈


一期的个性化只在最末端的排序里有一点点，召回侧和文案侧基本不带个性化。这本身就有个明显的问题：模块进入策展阶段时，候选池已经是"千人一面"了，再怎么排序也只是在一个普适候选集里挑顺序。

更关键的问题在排序模型本身。一期复用的是启发式检索沉淀下来的排序模型，跟 AI 搜的曝光形态、内容形态、消费意图都对不齐。这正是泛搜模块在综合页里输给最佳匹配最直接的原因：最佳匹配是搜索域沉淀多年的成熟模型，AI 搜用的是推荐域的"借兵"，跨场景跑当然劣势。

二期会做两件事：把个性化从末端往前推到召回（让候选池本身就千人千面），并基于 AI 搜自己积累的"搜索曝光-点击-有效播放"样本，训一个 AI 搜模块专属的排序模型。

五、二期破局：三条主线

一期证明了 AI 搜的方向是对的，二期要让它真的“懂”且“快”：内容理解做厚、链路做透、个性化做深，三件事一起做。总纲一句话：**离线 + 在线两手抓，重数据、重业务理解，轻外部大模型依赖**。一期能上线靠的是大模型一时之力，二期要把这种“借力”沉淀成系统的内生能力。



5.2 主线二：在线化（动脉）

目标。把核心链路从分钟级压到秒级，让 AI 搜真正具备"在线下发"的能力，覆盖摆脱圈选限制。

子项 1：NLU 后训练蒸馏（CoT 内化）

意图识别是 AI 搜在线链路上最重的一环。一期走的是大模型显式 CoT 路线，把推理过程一步步吐出来，token 开销巨大、RT 长。核心矛盾是规则太多 → PE 太长 → 延迟高 + 注意力稀释 + 成本高。再靠 prompt 工程已经压不动了，二期的本质思路是把"规则"从 prompt 里搬进模型权重，让小模型直接学到大模型的判断。


二期的方案是 双教师软硬结合蒸馏 + 投机解码部署：

双教师软硬结合蒸馏。用两位教师同时打标。硬标签来自一个高准确率的大模型，提供"标准答案"保正确性；软标签来自一个同家族大模型，提供 token 级的概率分布保泛化能力。学生模型（4B 量级）的训练损失是两者的加权融合：

Loss = α · CE(hard label) + (1-α) · T² · KL(soft logits)

单条样本承载的信息量比纯硬标签蒸馏大得多，能用更少的数据把上万 token 的 PE 规则压进 4B 小模型，对意图细、维度多、长尾多的 NLU 任务比纯硬蒸馏更稳。这里有一个工程上的硬约束：软标签教师必须跟学生同家族，tokenizer 才对齐、KL 散度才算得上准。


投机解码部署。蒸完 4B 之后再蒸一个 0.8B 的 Draft 模型做投机解码加速："Draft 小模型快速猜一段、Target 4B 一次性批改"，靠并行优势把延迟再压一档。



这套 NLU 蒸馏能力由觅乐底座承担，搜推 AGENT 项目可以直接复用同一份 Target / Draft 模型和投机解码服务，跨项目共享投入产出。

子项 2：RAG 文案生成

一期的文案是 LLM 从零写出来的，慢且容易幻觉。二期改成三段式：



这种结构最大的好处是把“写文案”这件事的上限分成了两段：事实准确性由检索决定，表达流畅性由生成器决定。两段独立优化、独立评测，比一期“一锅炖”清楚得多。**关键点：RAG 召回质量决定文案上限。**这也是为什么主线一必须先做扎实，主线二的 RAG 才有底气。没有高质量的知识源，再好的 RAG 框架也是空壳。

5.3 主线三：个性化召排（肌肉）

目标。把个性化从一期的“末端排序兜底”扩展到“召回 + 排序 + 文案 + 意图”全链路，让用户在任何一个环节看到的都不是同一份候选。

子项 1：个性化召排

把召回和排序作为一组动作一起升级。

个性化召回：召回 + 排序

召回提供千人千面的候选池，排序在搜索域样本上把“用户当下偏好”信号学透，两层一起把个性化补到位



召回侧。一期召回基本不带个性化，候选池“千人一面”，再怎么排序也只是在普适集合里挑顺序。二期把用户长短期行为序列与 query 联合建模，做 query × user 双塔或 target-attention，并扩 vector quantization 的码本规模、引入用户偏好侧信息，最终多路融合。

排序侧。一期借的是启发式检索沉淀下来的推荐域模型，搜索场景下有 domain gap，这是泛搜模块在综合页里输给最佳匹配最直接的原因。二期会基于 AI 模块自己积累的曝光-点击-有效播放数据，训一个搜索域专属的排序模型。

召回提供“千人千面的候选池”，排序在搜索域样本上把“用户当下偏好”的信号学透，两层一起把个性化补到位。

子项 2：个性化 CoT 意图识别

意图识别是个性化的入口。二期希望让模型不只理解 query 的字面意图，还能结合用户人群画像和历史偏好做推理：同一句“婚礼上放的歌”，对偏粤语流行的用户和偏英文经典的用户，推理出的意图标签集应该是不一样的。

落地方式两条路径协同：

- **离线：**基于人群画像做泛搜个性化标签的批量推理，结果落库供下游召排消费，覆盖热门 query；
- **在线：**走主线二（觅乐底座）蒸馏后的小模型做流式生成，毫秒级返回，覆盖长尾。

这一步让“个性化”不再只发生在排序里，而是从意图识别这一步就开始介入。

5.4 三条主线的关系

主线之间不是平行的，是 **地基** → **动脉** → **肌肉** 的递进关系：

主线	角色	解决的瓶颈	主要承载
内容 & Query 理解	地基	理解上限够、密度不够	觅乐基建
在线化	动脉	链路卡在分钟级 RT	觅乐基建 + AI 搜业务
个性化召排	肌肉	个性化只在末端	AI 搜业务

一句话总结要害：**内容理解做厚** → **在线化做透** → **个性化做深**。一期证明了 AI 搜的方向是对的；二期借觅乐的底座，要让它真的"懂"且"快"。

六、从一个模块到一个搜索智能体

一期，AI 搜是综合页里的一个卡片。二期及以后，它会演进为一个独立的"搜索智能体"。

需要先把这件事的边界说清楚：搜索智能体不等于"音乐陪伴助手"。AI 搜的定位不是去陪用户聊天，也不是做泛在的音乐对话伙伴，重点始终落在搜索本身：**更精准地激发用户的搜索意图，更深入地满足用户的搜索需求**。多轮、记忆、词引导这些能力都是为这个目标服务的工具，不是目标本身。

第一章里讲过两类用户需求：显性的宽泛搜索占 30%，被压抑的沉默需求"可能比 30% 还大得多"。一期解决的是"用户敢说出来的那部分"，他们已经在搜索框里输入了某种模糊描述，AI 搜把这部分需求接住、策展呈现出来。但还有一类用户根本不会主动输入完整需求，可能因为想不清楚，也可能因为以前从来没被搜索系统好好接住过。从模块升级到智能体的本质，就是把这部分"还没被表达出来的需求"也激发出来，再帮他们一步步满足。

具体形态上有三个交互升级方向：

形态升级	内容	解决的问题
A2UI 独立落地页	跟着搜索热点 A2UI 的节奏，AI 搜从综合页一个卡片演进成独立落地页，承载多轮、词引导、卡片化结果	给"搜索"一个不被屏效抢占的专属舞台
Memory + 多轮交互	用户长短期记忆、Session State、追问 / 澄清 Planner、上下文一致性	用户不需要一次把需求讲完整，可以边聊边把意图聊清楚
二轮词引导	基于当前结果和用户兴趣生成探索词，点击后 query 改写续接	用户不知道下一步搜什么的时候，系统主动给出探索方向

三件事合在一起，把"搜索"从一次性的字面查询扩展成多轮、连续、被引导的探索过程。AI 搜在这里扮演"搜索的副驾"：用户给出一点意图，系统接住、追问、推荐；用户没想好下一步时，系统主动给出探索方向。这套形态能立得住，靠的不是几个交互组件，而是第五章三条主线的能力底座：内容理解给它一份可调用的音乐知识地图，在线化让多轮对话不被分钟级 RT 卡死，个性化召排让"千人千面"贯穿到每一步。

交互形态之外，二期产品形态还有另一半要同步迭代，也就是**分发形态**：

- 一期的 AI 搜在分发上还是"惊喜掉落"模式：圈定一部分 query 才走 AI 链路、圈定一部分歌才进入候选池、有的形态还需要用户点一下才能展开。本质上是一种偶遇，这对一期上线、控成本是合理的，但长期会有两个副作用：
- 用户对"AI 搜能做什么"形成不了稳定预期
- AI 生产的内容资产也摆脱不了"专属模块"的边界
- 二期要往"稳定心智"迭代，做两件事：
- 一是**从惊喜模式走向预期模式**，圈选范围扩到全量、点击触发改为默认承接、不同 query 看到的 AI 形态稳定化，让用户每次搜索都清楚"AI 搜会接住我什么、用什么形态接住"；
- 二是**从专属模块走向多资源参与分发**，第五章主线一沉淀的歌曲多维主题、query 意图细分、卷首语 / 推荐理由 / 解读这些内容资产，不再只在 AI 模块里露出，而是作为多资源之一参与到歌单页、艺人页、播放页、评论页等更广泛的分发场景里，跳出"AI 模块边界"做非常规分发

两件事的本质：**AI 搜不再是"搜索结果页里偶遇的彩蛋"，而是"用户可以预期、全站可以复用"的稳定能力。**

一期已经证明了"在网易云的搜索场景里，AI 有空间做事"，二期要做的，是把这个空间真正做成一个**能激发表达、跟进意图、把搜索从"找到"扩展到"探索"的智能体**，并且让它生产的内容资产能稳定地分发到全站，沉淀的增量用户偏好信号能反哺到全站。搜索这件事正在被重新定义，AI 搜要做的，是让这场重新定义在网易云真正落地。

写在最后：路还长，但方向已经清晰。下一篇，见。

致谢

AI 搜一期能上线、能复盘、能继续往下走，靠的是一支跨职能小队拧成一股绳：产品组邹嘉钰、宋紫岚、朱圣意定方向、给洞察；算法组浩麒、寒蕊、友日、周仨、海通打磨内容理解、召回、排序；服务端刘俊峰、黄磊磊在线接入和安全过审；前端赵桂雄、庄毓勋落地A2UI展示样式；UI交互安永生、徐竹君在用户体验层面的细致把关；数据分析郭林蔚对场景下指标细粒度的分析。每一条线都缺一不可，感谢大家。